

MESTRADO INTEGRADO EM ENGENHARIA INFORMÁTICA GRAMÁTICAS NA COMPREENSÃO DE SOFTWARE

Q&A do FAQ da Univerdade do Minho

a
78679 - Diana Ribeiro Barbosa a
78821 - José Carlos Lima Martins 7 de Janeiro de 2019

Resumo

Neste trabalho é relatado o desenvolvimento de um Q&A System com área de conhecimento a FAQ da Universidade do Minho. De forma a desenvolver este sistema, foi usado os conhecimentos de programação de linguagens. Dentro desses conhecimentos, foi aplicado as Gramáticas Independentes de Contexto e Gramáticas de Atributos, usando a notação ANTLR.

Conteúdo

| 1 | Introdução | 1 |
|----------|------------------------------------|---|
| 2 | Área de Conhecimento | 1 |
| 3 | Funcionalidades suportadas | 2 |
| 4 | Gramática Independente de Contexto | 3 |
| 5 | Gramática de Atributos | 4 |
| 6 | Conclusão | 7 |
| A | Gramática Independente de Contexto | 7 |
| В | Gramática de Atributos | 8 |

1 Introdução

O objetivo deste trabalho é o desenvolvimento de um $Q\mathcal{E}A$ System, isto é, um sistema de perguntas e respostas aplicando os conhecimentos adquiridos ao longo do semestre na unidade curricular de Gramáticas na Compreensão de Software sobre gramáticas de atributos, gramáticas independentes de contexto, qualidade de gramáticas, entre outros.

Um Q&A System [2] é um programa que tenta responder a perguntas colocadas por utilizadores. Como exemplos de Q&A Systems pode-se tomar o Quora, o Yahoo! Answers e o Stack Overflow. Normalmente, cada um destes sistemas tem uma área de conhecimento na qual opera, possuindo as respostas às principais perguntas relativas a área. A área de conhecimento que escolhemos é a FAQ da Universidade do Minho.

Assim, na secção 2 damos a conhecer e aprofundamos um pouco sobre a área de conhecimento escolhida. Na secção 3, são indicadas as funcionalidades suportadas pelo sistema desenvolvido. Numa outra secção, 4, é explicada a GIC construída e a estrutura lógica do programa. Além disso, na secção 5, são apresentadas as funções e uso de atributos que suportam as funcionalidades disponibilizadas. Por fim, na secção 6, é feita uma análise crítica ao trabalho e possíveis melhorias.

2 Área de Conhecimento

A área de conhecimento escolhida para o trabalho desenvolvido foi o FAQ (Frequently Asked Questions) [1] da Universidade do Minho. O seu objetivo é responder às

questões mais frequentes colocadas pelos alunos diminuindo o volume de emails enviados e de idas aos vários serviços da universidade (e.g. Serviços Académicos, Serviços de Ação Social, Serviços de Documentação, Serviços de Relações Internacionais, Direção de Recursos Humanos, ...). Essencialmente aumentar a sua eficiência. Assim, tem como vantagem a redução do tempo de espera quer de resposta aos *emails* quer das filas no atendimento presencial.

O tema da informação guardada na base de conhecimento é a Universidade do Minho, nomeadamente, informação relativa ao calendário escolar, pagamento de propinas, admissão aos cursos, recrutamento de investigadores, residências universitárias, ECTSs, inscrições, campi e matrículas, entre outros. Quanto aos utilizadores, o sistema destina-se a uso por parte de alunos (que já frequentem a universidade ou que o pretendam fazer no futuro), alumni, corpo docente, investigadores, funcionários ou membros da direção.

Alguns exemplos de perguntas possíveis a que o $Q \mathcal{E}A$ System poderá dar resposta (contando que a informação seja corretamente inserida na base de conhecimento) são:

- O que são ECTSs?
- Onde me posso candidatar à Universidade do Minho?
- Como posso fazer *Erasmus*?
- Onde me devo dirigir para assuntos relacionados com bolsas de estudo?
- Qual é o calendário escolar da Escola de Engenharia?

3 Funcionalidades suportadas

O $Q\mathcal{E}A$ system desenvolvido suporta várias funcionalidades que consideramos essenciais. O nosso objetivo era a criação de um sistema eficiente e intuitivo. Neste sentido, delineamos um conjunto de metas a atingir ao longo da realização do projeto, nomeadamente, funcionalidades a serem suportadas pelo sistema a nível da sua capacidade de resposta.

A lista é a que se segue:

- Case das letras (maiúsculo/minúsculo) não interferir com o reconhecimento da pergunta;
- Reconhecer perguntas que terminem em vários/múltiplos sinais de pontuação;
- Devolver a resposta guardada na Base de Conhecimento cuja intenção seja o mais semelhante à questão colocada;
- Caso não haja uma correspondência que se destaque de entre as existentes, havendo várias com o mesmo nível de igualdade, devolver essas mesmas respostas;
- Informar o utilizador da ausência de informação relativa à questão colocada;
- Reconhecer várias perguntas numa só questão.

Estes objetivos foram alcançados, sendo possível verificar na figura 1 *inputs* sintaticamente corretos, isto é, que o sistema reconhece conforme as regras definidas.

```
Gostava de saber quando se pagam as propinas de 2018/19 ...
R0:' Até dia 23 de julho .'

Siri, diz-me: O QUE SÃO ECTS ?!
R0:' European Credit Transfer System .'

Qual é o nome do reitor ?

Não foi encontrada resposta à sua pergunta.

ola, onde nos devemos inscrever para o exame de Época Especial ?
R0:' Incrições para exame de Época Especial são feitas no portal académico. '
```

Figura 1: Exemplo do funcionamento do Q&A System FAQ UMinho

4 Gramática Independente de Contexto

É possível identificar duas componentes principais do sistema: a Base de Conhecimento - composta por pares (pergunta,resposta) - e as Questões colocadas pelos utilizadores. Na prática, estas correspondem às seguintes produções definidas na gramática:

'bcQAS': define a estrutura da base de conhecimento, nomeadamente, pares (intenção, resposta). A intenção é o equivalente à pergunta. Nela estão guardados o tipo (e.g. 'Qual', 'Como', 'Onde'), a ação (e.g. 'imprimir', 'inscrever') e as keywords associadas (e.g. 'propinas', 'regulamento', 'exame'). Este conhecimento é lido e guardado para possibilitar a resposta às questões. Caso se deseje expandir a base de conhecimento e os novos pares incluam vocabulário novo, apenas é necessário adicionar os termos nas produções 'tipo', 'acao' e 'keyword'.

```
bcQAS: par+
   ;
par: '(' intencao ';' resposta')'
   ;
intencao: tipo ',' acao ',' keywords
    :
```

A partir do excerto da GIC acima, é possível constatar que a base de conhecimento é constituída por pares, cada par com 2 campos separados por um ponto e virgula. O primeiro ('intencao') permite identificar a que perguntas a resposta se pode associar. O segundo ('resposta') contém a frase que deve ser apresentada aos utilizadores caso o sistema considere que a questão colocada está relacionada com este conhecimento. A base de conhecimento é identificada inicialmente pela palavra reservada "BC:". Alguns exemplos de pares pergunta-resposta sintaticamente corretos que podem ser adicionados são:

```
BC:
( Quando , pagar , [ propinas ] ; ' Até dia 23 de julho .')
( Qual , ser , [ email , diretor , curso ] ; ' ddd@ddd.com. ')
```

'questoes': define a estrutura das perguntas a responder. Cada questão é composta por palavras que o sistema reconhece, (tipos, acções e keywords) que são usadas no processo de obtenção de respostas, por palavras que o sistema não conhece (que podem ser também tipos, ações e keywords com cases diferentes, noutros tempo verbais, ou então palavras irrelevantes como por exemplo pronomes), por fim, terminadas com sinais de pontuação (um ou mais pontos de interrogação, exclamação ou finais).

```
questoes: questao+
;
questao: (PALAVRA | tipo | acao | keyword )+ PONTOTERMINAL+
;
```

A secção das questões, para ser reconhecida corretamente, deve ser inicializada pela palavra reservada "QUESTOES:", tal como definido na gramática. É possível observar na figura 1 vários exemplos de questões sintaticamente corretas.

Encontra-se em anexo na secção A a Gramática Independente de Contexto para observação mais detalhada.

5 Gramática de Atributos

De forma a pôr o trabalho funcional, isto é, criar os mecanismos de resposta procedeu-se à transformação da gramática de uma GIC (gramática independente de contexto) para uma GA (gramática de atributos).

A criação da base de conhecimento é feita através da produção 'bcQAS'. Os pares pergunta-resposta são lidos do ficheiro de teste e guardados num hashmap cujas chaves são os 'tipos' das intenções (e.g. 'Como', 'Quando', ...) e os valores são Arraylists de pares (intencao, resposta). Um objeto do tipo Par contém o tipo, a ação, as keywords e informação associada, correspondendo essencialmente a um par pergunta-resposta da base de conhecimento. Esta decisão foi tomada para tornar a procura mais eficiente.

```
bcQAS returns [HashMap<String, ArrayList<Par>> bc]
@init{$bcQAS.bc = new HashMap<String,ArrayList<Par>>();}
    : t1=par [$bcQAS.bc] (t2=par [$t1.bcOut] {$t1.bcOut = $t2.bcOut;})*
;

par [HashMap<String, ArrayList<Par>> bcIn]
    returns [HashMap<String, ArrayList<Par>> bcOut]
    : '(' intencao ';' resposta')'
    {
        $intencao.p.resposta = $resposta.val;
        ArrayList<Par>> aux = $bcIn.get($intencao.p.tipo);
        if(aux==null) aux = new ArrayList<Par><();
        aux.add($intencao.p);</pre>
```

Por outro lado, é importante também nos debruçarmos sobre o processo de resposta. A produção responsável por responder às questões colocadas é a 'questao'. Aqui são reconhecidas as várias palavras que compõem uma pergunta que podem já existir na base de conhecimento, nomeadamente, tipos, ações e keywords, mas também palavras que não sejam conhecidas. Cada questão é composta por pelo menos uma palavra e terminada por pelo menos um ponto terminal.

```
questao [HashMap<String, ArrayList<Par>> bc]
@init{
    ArrayList<String> tipos = new ArrayList<String>();
    ArrayList<String> acoes = new ArrayList<String>();
    ArrayList<String> keywords = new ArrayList<String>();
    ArrayList<String> palavras = new ArrayList<String>();
    StringBuffer question = new StringBuffer();
}
    :( PALAVRA { palavras.add($PALAVRA.text);
                 question.append($PALAVRA.text).append(" ");
    | tipo { tipos.add($tipo.val);
             question.append($tipo.val).append(" ");
    | acao { acoes.add($acao.val);
             question.append($acao.val).append(" ");
    | keyword { keywords.add($keyword.val);
                question.append($keyword.val).append(" ");
     )+ (PONTOTERMINAL {question.append($PONTOTERMINAL.text);} )+
    {getAnswer($bc,question,tipos,acoes,keywords,palavras);}
```

Quando é reconhecida uma pergunta completa, procede-se à tentativa de obtenção de resposta. Esta fica ao encargo do método getAnswer definido no @members. Esta

tenta obter um match completo das palavras extraídas da questão, com a parte da intenção dos pares (intençao, resposta) que contêm o conhecimento. Se isto não for possível, tenta otimizar o mais possível.

Exemplificando, para a base de conhecimento abaixo os resultados esperados seriam os seguintes.

```
( Quando , pagar , [ propinas ] ; ' Até dia 23 de julho .')
( O que , ser , [ ECTS ] ; ' European Credit Transfer System .')
( Qual , ser , [ email , diretor , curso ] ; ' ddd@ddd.com. ')
( Como , aceder , [ calendário , escolar ] ;
       'O calendário escolar está disponível no portal académico.')
( Como , imprimir , [ calendário , escolar ] ;
       'O calendário escolar pode ser imprimido através do portal académico.')
( Onde , inscrever , [ exame , época , especial ] ;
       'Incrições para exame de Época Especial são feitas no portal académico. ')
( Onde , inscrever , [ exame , época , recurso ] ;
       'Não é necessária incrição para realizar exame de recurso. ')
Gostava de saber quando se pagam as propinas de 2018/19 ...
RO:' Até dia 23 de julho .'
Siri, diz-me: O QUE SÃO ECTS ?!
RO: ' European Credit Transfer System .'
Qual é o nome do reitor ?
Não foi encontrada resposta à sua pergunta.
ola, onde nos devemos inscrever para o exame de Época Especial ?
RO: 'Incrições para exame de Época Especial são feitas no portal académico.'
Onde nos devemos inscrever para o exame de Época de Recurso ?
RO: 'Não é necessária incrição para realizar exame de recurso.'
Onde nos devemos inscrever para o exame de recurso ?
RO:' Não é necessária incrição para realizar exame de recurso. '
Onde nos devemos inscrever para o exame ?
RO: 'Incrições para exame de Época Especial são feitas no portal académico.'
R1:' Não é necessária incrição para realizar exame de recurso. '
Como aceder para imprimir o calendário escolar ?
RO: 'O calendário escolar está disponível no portal académico. '
R1: O calendário escolar pode ser imprimido através do portal académico. '
```

A Gramática de Atributos e versão final do Q & A System com área de conhecimento sendo a FAQ da Universidade do Minho pode ser visualizada em anexo na secção B.

6 Conclusão

Com a realização deste trabalho, foi-nos possível concluir que as várias funcionalidades proporcionadas pelas Gramáticas de Atributos (a atribuição de valores a atributos associados às produções de uma gramática formal) permitem a construção de programas e linguagens bastante poderosas de forma simples, visualmente legível e de fácil compreensão.

Partindo destas vantagens fornecidas, fomos capazes de desenvolver um programa bem consolidado que permite, a partir de conhecimento prévio acerca de uma área específica, responder a várias questões colocadas pelo utilizador envolvendo múltiplas áreas e serviços da Universidade do Minho.

Contudo, uma das melhorias que poderia ser feita no futuro ao programa desenvolvido é o carregamento do vocabulário a ser usado na base de conhecimento e.g tipos (Qual, Como, ...), ações (imprimir, inscrever,...) e as keywords (exame, reitor,...) ser feito a partir do ficheiro de teste. Isto permitiria uma maior flexibilidade, sendo possível reaproveitar a mesma gramática para várias áreas de conhecimento diferentes, bastando apenas usar ficheiros de teste diferentes.

Referências

- [1] FAQ. https://dictionary.cambridge.org/us/dictionary/english/faq. Acedido em 03 de Janeiro de 2019.
- [2] Q&A software. https://en.wikipedia.org/wiki/Q%26A_software. Acedido em 03 de Janeiro de 2019.

A Gramática Independente de Contexto

```
grammar QASystemGIC;

qas: 'BC:' bcQAS 'QUESTOES:' questoes
;

questoes: questao+
;

questao: (PALAVRA | tipo | acao | keyword )+ PONTOTERMINAL+
;

bcQAS: par+
;

par: '(' intencao ';' resposta')'
;

intencao: tipo ',' acao ',' keywords
;
```

B Gramática de Atributos

```
grammar QASystemGA;

@header{
    import java.util.*;
    import java.util.stream.Collectors;
}

@members{
    class Par{
        String tipo;
        ArrayList<String> acoes;
        ArrayList<String> keywords;
        String resposta;

    public String toString(){
            StringBuffer sb = new StringBuffer();
```

```
sb.append("t = ");
         sb.append("("+this.tipo+",");
         sb.append(Arrays.toString(this.acoes.toArray())+",");
         sb.append(Arrays.toString(this.keywords.toArray())+")");
         return sb.toString();
    }
}
boolean containsElemList(ArrayList<String> 11, ArrayList<String> 12, int n){
    boolean ret=false;
    int size1 = l1.size();
    int size2 = 12.size();
    int matches=0;
    for(int i=0; i<size1 && !ret; i++)</pre>
        for(int j=0; j<size2 && !ret; j++) {</pre>
            ret=12.get(j).toLowerCase().equals(11.get(i).toLowerCase());
        }
    if(matches>n) n = matches;
    if (matches<n) return false;</pre>
    return ret;
}
boolean containsAllKeywords(ArrayList<String> 11, ArrayList<String> 12){
    boolean ret=false;
    int size1 = 11.size();
    int size2 = 12.size();
    int nkeys = 12.size();
    if(size2==0) return false;
    for(int i=0; i<size1 && nkeys>0; i++)
        for(int j=0; j<size2 && nkeys>0; j++)
            if (12.get(j).toLowerCase().equals(11.get(i).toLowerCase()) == true) {
                nkeys--;
    if(nkeys==0) return true;
    else return false;
}
/* cria lista com as keywords presentes na BC*/
ArrayList<String> addkeywords (ArrayList<String> 1, ArrayList<Par> t) {
    ArrayList<String> k = new ArrayList<String>();
    for (Par pair : t)
        for (String s : pair.keywords)
            if(!1.contains(s)) 1.add(s);
    return 1;
}
```

```
/* Obtém a(s) resposta(s) para cada questão */
void getAnswer(HashMap<String, ArrayList<Par>> bc, StringBuffer question,
               ArrayList<String> tipos, ArrayList<String> acoes,
               ArrayList<String> keywords, ArrayList<String> palavras){
    int tipoSize = tipos.size();
    ArrayList<String> keywordsBC = new ArrayList<String>();
    ArrayList<String> keywordsPalavras = new ArrayList<String>();
    ArrayList<String> resp;
    ArrayList<String> respteste;
    ArrayList<Par> aux = new ArrayList<Par>();
    for(ArrayList<Par> 1 : bc.values())
        keywordsBC = addkeywords(keywordsBC,1);
    if(tipoSize>0){
        for(int i=0;i<tipoSize;i++)</pre>
            aux.addAll(bc.get(tipos.get(i)));
    }else{
        for(ArrayList<Par> 1 : bc.values())
            aux.addAll(1);
    }
    for (String s : palavras) {
        if(keywordsBC.contains(s.toLowerCase()))
            keywordsPalavras.add(s);
    }
    if(keywordsPalavras.isEmpty())
        for(String s : keywords)
           keywordsPalavras.add(s);
    int x=0;
   respteste = aux.stream()
       .filter(a -> containsElemList(a.acoes,acoes,x) || containsElemList(a.acoes,palavras,x))
       .filter(a -> containsAllKeywords(a.keywords,keywords) && containsAllKeywords(a.keywordsPalavras))
       .filter(a -> containsAllKeywords(a.keywords,keywordsPalavras))
       .map(a -> a.resposta)
       .distinct()
       .collect(Collectors.toCollection(ArrayList::new));
    if(!respteste.isEmpty()) {
        System.out.println("\n"+question.toString());
        int w=0;
        for(String r : respteste)
            System.out.println("R" + w++ + ":" + r);
    } else {
        int n=0;
```

```
resp = aux.stream()
                      .filter(a -> containsElemList(a.acoes,acoes,n) || containsElemList(a.acoes,palavras,n))
                      .filter(a -> containsElemList(a.keywords,keywords,n) || containsElemList(a.keywords,palavras,n))
                      .map(a -> a.resposta)
                      .distinct()
                      .collect(Collectors.toCollection(ArrayList::new));
            System.out.println("\n"+question.toString());
            int w=0;
            for(String r : resp)
                System.out.println("R" + w++ + ":" + r);
            if (resp.isEmpty()) System.out.println("Não foi encontrada resposta à sua pergunta.");
    }
}
qas: 'BC:' bcQAS 'QUESTOES:' questoes [$bcQAS.bc]
questoes [HashMap<String, ArrayList<Par>>> bc]: (questao [$questoes.bc])+
questao [HashMap<String, ArrayList<Par>> bc]
@init{
    ArrayList<String> tipos = new ArrayList<String>();
    ArrayList<String> acoes = new ArrayList<String>();
    ArrayList<String> keywords = new ArrayList<String>();
    ArrayList<String> palavras = new ArrayList<String>();
    StringBuffer question = new StringBuffer();
    : (PALAVRA {palavras.add($PALAVRA.text); question.append($PALAVRA.text).append(" ");}
    | tipo {tipos.add($tipo.val); question.append($tipo.val).append(" ");}
    | acao {acoes.add($acao.val); question.append($acao.val).append(" ");}
    | keyword {keywords.add($keyword.val); question.append($keyword.val).append(" ");} )+
    (PONTOTERMINAL {question.append($PONTOTERMINAL.text);} )+
    {getAnswer($bc,question,tipos,acoes,keywords,palavras);}
bcQAS returns [HashMap<String, ArrayList<Par>> bc]
@init{$bcQAS.bc = new HashMap<String,ArrayList<Par>>();}
    : t1=par [$bcQAS.bc] (t2=par [$t1.bcOut] {$t1.bcOut = $t2.bcOut;})*
par [HashMap<String, ArrayList<Par>> bcIn] returns [HashMap<String, ArrayList<Par>> bcOut]
    : '(' intencao ';' resposta')'
    {
        $intencao.p.resposta = $resposta.val;
        ArrayList<Par> aux = $bcIn.get($intencao.p.tipo);
        if(aux==null) aux = new ArrayList<Par>();
        aux.add($intencao.p);
        $bcIn.put($intencao.p.tipo,aux);
```

```
$bcOut = $bcIn;
    }
intencao returns [Par p]
        : tipo ',' acao ',' keywords
             $intencao.p = new Par();
             $intencao.p.tipo = $tipo.val;
             $intencao.p.acoes = $acao.list;
             $intencao.p.keywords = $keywords.list;
        }
resposta returns [String val]
        : TEXTO {$resposta.val = $TEXTO.text;}
tipo returns [String val]
    : ( t='Porquê' | t='0 que' | t='Quando' | t='Onde' | t='Como' | t='Qual' | t='Quem') {$tipo.val = $t.text;}
acao returns [ArrayList<String> list, String val]
@init{$acao.list = new ArrayList<String>();}
     : 'aceder' {\$acao.list.add("aceder"); \$acao.list.add("acedo"); \$acao.val="aceder";}
     | 'imprimir' {\$acao.list.add("imprimir"); \$acao.list.add("imprimo"); \$acao.val="imprimir";}
     | 'ser' {\$acao.list.add("\u00e9"); \$acao.list.add("\u00e90");} \$acao.list.add("\u00e90");}
     | 'inscrever' {\$acao.list.add("inscrever"); \$acao.list.add("inscrevo"); \$acao.val="inscrever";}
     | 'pagar' {\$acao.list.add("pagar"); \$acao.list.add("pago"); \$acao.list.add("pagam"); \$acao.val="pagar";}
     'tem' {\$acao.list.add("tem"); \$acao.list.add("teve"); \$acao.list.add("tinha");}
     | 'haver' {\$acao.list.add("ha"); \$acao.list.add("havia"); \$acao.list.add("houve");}
     | 'funcionar' {\$acao.list.add("funcionar"); \$acao.list.add("funciona"); \$acao.list.add("funcionar\");}
keywords returns [ArrayList<String> list]
@init{$keywords.list = new ArrayList<String>();}
         : '[' k1=keyword {$keywords.list.add($k1.val);} ( ',' k2=keyword {$keywords.list.add($k2.val);})* ']'
keyword returns [String val]
        : ( t='propinas' | t='época' | t='especial' | t='email' | t='diretor' | t='curso'
        | t='portal' | t='académico' | t='Universidade' | t='Minho' | t='exame' | t='recurso'
       | t='calendário' | t='escolar' | t='reitor' | t='horário' | t='regulamento'
       | t='código' | t='ético' | t='conduta' | t='direitos' | t='deveres' | t='cadeira'
       | t='unidade' | t='curricular' | t='ECT' | t='ECTS' | t='Erasmus') {\text{keyword.val=$t.text;}}
/* Definição do Analisador Léxico */
TEXTO: (('\'') ~('\'')* ('\''));
fragment LETRA : [a-zA-Za\acute{e}i\acute{o}u\acute{A}\acute{e}I\acute{O}u\~{A}\~{a}\~{O}\~{o}a\^{e}\^{o}\^{A}\^{E}\^{O}\grave{A}\grave{E}\grave{I}\grave{O}u\grave{a}\grave{e}\grave{i}\grave{o}u\~{C}\varsigma] ;
```

```
fragment DIGITO: [0-9];
fragment SIMBOLO : [-%$\infty 0&()\[\]:{}=><+*;, oa~^/\'"];
PONTOTERMINAL: [?.!];
PALAVRA: (LETRA | DIGITO | SIMBOLO)+;
Separador: ( '\r'? '\n' | ' ' | '\t' )+ -> skip;
```